

Project Proposal

From Text to Insight: Analisi dei dati e interpretazione linguistica dei commenti YouTube su Stranger Things 5

1. Contesto del progetto

Le piattaforme di social media generano grandi quantità di dati testuali non strutturati contenenti opinioni, emozioni, aspettative e valutazioni espresse spontaneamente dagli utenti. Questi dati possono fornire informazioni utili sulle reazioni del pubblico ai prodotti. Il progetto propone una pipeline end-to-end di Data Analytics e Natural Language Processing per analizzare il sentiment del pubblico. In questo specifico progetto, si tratta di commenti in lingua italiana pubblicati sotto il trailer ufficiale di Stranger Things 5 sul canale Netflix Italia. Il progetto è concepito come un caso di studio in cui l'analisi computazionale viene combinata con l'interpretazione linguistica. L'obiettivo, pertanto, non è limitato alla misurazione del sentiment o alla massimizzazione dell'accuratezza predittiva, ma consiste anche nell'indagare in che modo i fenomeni linguistici e pragmatici influenzino il comportamento e l'interpretazione dei modelli automatici. Il codice è reso riproducibile per qualsiasi dataset testuale.

2. Domanda di ricerca

La domanda di ricerca centrale è: *“Come possono Data Analytics e Natural Language Processing essere combinati per analizzare le reazioni del pubblico a un evento mediatico fortemente atteso e quali fenomeni linguistici influenzano le prestazioni e l'interpretazione dei modelli automatici di classificazione del testo?”*

La domanda viene affrontata attraverso tre prospettive analitiche complementari:

1. Sentiment Analysis — Quale polarità emotiva viene assegnata automaticamente ai commenti del pubblico?

2. Supervised Machine Learning — In quale misura un modello lessicale tradizionale è in grado di riprodurre le etichette di sentiment generate da un modello Transformer?

3. Unsupervised Machine Learning — Esistono nel corpus pattern lessicali e tematici ricorrenti che possono essere identificati senza etichette predefinite?

Un'interpretazione qualitativa finale esamina i fenomeni linguistici che possono spiegare gli errori del modello e le classificazioni inattese.

3. Dataset

Il corpus è stato raccolto appositamente per il progetto a partire dai commenti pubblicamente disponibili associati al trailer ufficiale italiano di *Stranger Things 5* su YouTube. L'estrazione iniziale ha prodotto 884 commenti. Dopo la pulizia dei dati, la rimozione dei duplicati e l'esclusione dei record non informativi, il corpus finale contiene 866 commenti unici in lingua italiana.

Le variabili disponibili includono:

- *testo del commento*;
- *autore*;
- *data di pubblicazione*;
- *numero di Like*

I dataset grezzo e processato sono mantenuti concettualmente separati, al fine di preservare la distinzione tra dati raccolti e dati utilizzati per l'analisi.

4. Metodologia

Il progetto segue una pipeline end-to-end:

Raccolta dei dati

|

Pulizia dei dati e preprocessing linguistico

|

Analisi esplorativa dei dati

|

Sentiment Analysis basata su Transformer

|

Rappresentazione TF-IDF

|

Regressione Logistica

|

Valutazione del modello

|

Clustering K-Means

|

Interpretazione linguistica

4.1 Raccolta dei dati

I commenti vengono raccolti dal trailer ufficiale italiano attraverso un workflow di estrazione dei commenti da YouTube basato su Python. Il corpus risultante rappresenta una forma di lingua digitale spontanea caratterizzata da scrittura informale, espressioni emotive, riferimenti a personaggi ed eventi fittizi, nostalgia, aspettative, ironia e conoscenze culturali condivise.

4.2 Pulizia dei dati e preprocessing linguistico

La fase di preprocessing comprende:

- *rimozione dei duplicati;*
- *rimozione dei commenti vuoti o non informativi;*
- *conversione in minuscolo;*
- *rimozione degli URL;*
- *rimozione delle menzioni degli utenti;*
- *pulizia della punteggiatura e dei caratteri speciali;*

- *rimozione delle stopwords;*
- *tokenizzazione;*
- *lemmatizzazione.*

Il testo processato viene memorizzato nella variabile ``clean_text``. Vengono inoltre calcolate variabili descrittive quali il numero di parole e il numero di caratteri. Il progetto utilizza spaCy con il modello italiano ``it_core_news_lg``.

4.3 Analisi esplorativa dei dati

L'EDA viene utilizzata per descrivere il corpus prima della fase di modellazione.

L'analisi comprende:

- *statistiche descrittive;*
- *distribuzione della lunghezza dei commenti;*
- *identificazione degli outlier;*
- *analisi delle frequenze lessicali;*
- *identificazione delle parole più frequenti.*

L'analisi di riferimento riporta una lunghezza mediana dei commenti di 5 parole, una media di circa 7,6 parole e un massimo di 315 parole.

4.4 Sentiment Analysis basata su Transformer

Ai commenti viene applicato un modello italiano di sentiment pre-addestrato appartenente alla famiglia Feel-IT.

Per ciascun commento, la pipeline memorizza:

- *etichetta di sentiment;*
- *punteggio di confidenza.*

Le tre categorie sono Positive, Negative e Neutral.

L'analisi di riferimento riporta:

| *Sentiment* | *Percentuale* |

| *Negative* | 46,1% |

| *Positive* | 33,6% |

| *Neutral* | 20,3% |

Questi risultati vengono interpretati con cautela, poiché il linguaggio emotivo negativo può esprimere nostalgia, paura della conclusione, tristezza o attaccamento emotivo, anziché una valutazione negativa della serie o del trailer.

4.5 Supervised Machine Learning

Le etichette di sentiment generate dal Transformer vengono utilizzate come variabile target per un esperimento di Regressione Logistica. L'obiettivo non è costruire un classificatore di sentiment indipendente basato su annotazioni umane. L'esperimento verifica invece quanto del comportamento del Transformer possa essere approssimato utilizzando caratteristiche lessicali esplicite.

Il testo viene rappresentato tramite TF-IDF con:

- *unigrammi e bigrammi*;
- *`ngram\_range=(1, 2)`*;
- *`max\_features=3000`*.

I dati vengono suddivisi in 80% training set e 20% test set mediante stratificazione.

Il modello viene valutato attraverso:

- *accuracy*;
- *precision*;
- *recall*;
- *F1-score*;
- *matrice di confusione*.

L'analisi di riferimento riporta un'accuracy del 59,2%.

4.6 Interpretazione delle caratteristiche

I coefficienti della Regressione Logistica vengono analizzati per identificare le caratteristiche associate a ciascuna classe predetta.

Tra le caratteristiche rappresentative individuate nell'analisi figurano:

- *Negative*: `muore`, `paura`, `no`, `spoiler`, `male`;
- *Neutral*: `ok`, `anni`, `esatto`, `sottosopra`;
- *Positive*: `finalmente`, `spettacolo`, `queen`, `hype`, `bello`.

Questa fase supporta l'interpretazione linguistica del comportamento del modello e mette in evidenza la differenza tra segnali emotivi a livello lessicale e valutazione a livello discorsivo.

4.7 Unsupervised Machine Learning

Il clustering K-Means viene applicato indipendentemente dalle etichette di sentiment, con l'obiettivo di esplorare la similarità lessicale all'interno del corpus.

Il progetto confronta:

- *TF-IDF basato su unigrammi*;
- *TF-IDF basato su unigrammi + bigrammi*.

L'analisi di riferimento mostra che l'inclusione dei bigrammi aumenta la dimensionalità senza migliorare in modo sostanziale la qualità del clustering. Il clustering finale utilizza pertanto una rappresentazione basata sugli unigrammi. L'Elbow Method e il Silhouette Score vengono utilizzati per valutare i diversi valori candidati di `k`. L'analisi seleziona `k=6` come compromesso operativo tra qualità della segmentazione e interpretabilità. I cluster risultanti sono fortemente sbilanciati, con un cluster che contiene 690 degli 866 commenti (79,4%). Questo risultato viene interpretato come indicatore di una sostanziale omogeneità lessicale e tematica, piuttosto che semplicemente come un fallimento del modello.

4.8 PCA e interpretazione dei cluster

La Principal Component Analysis (PCA) viene utilizzata per proiettare la rappresentazione TF-IDF in due dimensioni ai fini della visualizzazione. L'ispezione lessicale a livello di cluster viene quindi utilizzata per identificare nuclei tematici ricorrenti, tra cui:

- *Will e Vecna;*
- *la colonna sonora della Queen;*
- *reazioni emotive;*
- *nostalgia;*
- *ricordi e lunga storia della serie.*

I cluster vengono considerati raggruppamenti esplorativi e non categorie semantiche oggettivamente esistenti.

5. Risultati attesi

Il progetto mira a fornire:

1. *una descrizione quantitativa delle reazioni del pubblico;*
2. *una distribuzione del sentiment generata automaticamente;*
3. *una baseline interpretabile per la riproduzione delle classificazioni del Transformer;*
4. *una valutazione dei limiti delle caratteristiche lessicali;*
5. *una rappresentazione esplorativa dei pattern lessicali ricorrenti;*
6. *un'interpretazione qualitativa del comportamento del modello da una prospettiva linguistica.*

L'analisi completata mostra che il modello di Regressione Logistica riproduce solo una parte delle etichette generate dal Transformer e presenta prestazioni particolarmente scarse nella classificazione della classe Neutral.

6. Interpretazione linguistica

Un presupposto centrale del progetto è che le prestazioni di un modello non possano essere interpretate indipendentemente dalle caratteristiche linguistiche del corpus.

L'analisi considera pertanto fenomeni quali:

- *ironia;*
- *significato implicito;*
- *metafora;*
- *iperbole;*
- *polisemia;*

- *riferimenti culturali;*
- *conoscenza enciclopedica condivisa;*
- *contesto pragmatico;*
- *valutazione indiretta.*

Una distinzione interpretativa fondamentale è quella tra *polarità emotiva* e *valutazione dell'oggetto del discorso*. Per esempio, espressioni che coinvolgono paura, morte o tristezza possono ricevere un'etichetta di sentiment negativo anche quando chi scrive sta esprimendo entusiasmo e un forte coinvolgimento emotivo nei confronti della serie.

7. Limiti

Il progetto riconosce i seguenti limiti:

- *dimensione relativamente contenuta del corpus;*
- *etichette di sentiment generate automaticamente;*
- *assenza di un gold standard annotato manualmente;*
- *difficoltà nel modellare ironia e significato implicito;*
- *dipendenza dal contesto narrativo e culturale condiviso;*
- *omogeneità tematica del corpus;*
- *difficoltà nell'identificare il sentiment Neutral;*
- *clustering di un corpus specializzato relativo a un singolo evento mediatico.*

Questi limiti sono considerati parte del risultato analitico, poiché evidenziano i punti in cui le rappresentazioni computazionali non riescono a cogliere aspetti rilevanti del linguaggio naturale.

8. Considerazioni etiche

L'analisi riguarda commenti YouTube pubblicamente disponibili ed è condotta per finalità didattiche e di ricerca. L'attenzione analitica è rivolta ai pattern linguistici e computazionali aggregati, piuttosto che ai singoli utenti. Le informazioni personali non vengono utilizzate come variabili analitiche.

9. Tecnologie

- *Python 3*
- *Google Colab*
- *Pandas*
- *NumPy*
- *spaCy*
- *`it\_core\_news\_lg`*
- *Hugging Face Transformers*
- *Feel-IT*
- *scikit-learn*
- *Matplotlib*

Tecniche principali:

- *preprocessing linguistico;*
- *vettorizzazione TF-IDF;*
- *sentiment analysis basata su Transformer;*
- *Regressione Logistica;*
- *metriche di classificazione;*
- *matrice di confusione;*
- *clustering K-Means;*
- *Elbow Method;*
- *Silhouette Score;*
- *PCA.*

10. Valore

Il progetto dimostra la capacità di passare da dati testuali non strutturati a risultati analitici interpretabili:

Raccolta dei dati → Pulizia dei dati → NLP → EDA → Modelli Transformer → Machine Learning → Clustering → Visualizzazione → Interpretazione linguistica

Il principale valore del progetto risiede nella combinazione di metodi computazionali e analisi linguistica. Anziché presentare gli output del machine learning come autoesplicativi, il progetto considera il comportamento del modello come un oggetto di analisi e interpretazione. Questa prospettiva è particolarmente rilevante per applicazioni che coinvolgono NLP, analisi linguistica dell'AI, valutazione degli LLM, AI quality, annotazione di dati linguistici e human-centred AI.